

Senior Care Service 이중 모델 운영 계획

Llama 3.2:1B + Llama 3.2:3B 기반
대화 모드와 질의 모드 정의


핵심 구조	운영 원칙
1B는 평상시 일상 대화와 입력 해석을 담당하고, 3B는 건강 상태 확인이 필요할 때 RAG 후보 중 다음 질문을 선택한다.	Manager가 모드 전환, 최대 5회 질의, 답변 누적, 조기 종료, 대화 모드 복귀를 통제한다.

문서 목적

본 문서는 senior_care_service.py에서 두 개의 Ollama 모델을 운용하는 구조와, 일상 대화 모드 및 질의 응답 모드의 역할과 전환 원칙을 정의한다.

1. 전체 시스템 구조

시스템은 평상시 대화를 담당하는 1B 모델과, 건강 상태 확인 질의를 담당하는 3B 모델을 분리하여 사용한다. 두 모델을 직접 연결하지 않고 Manager가 호출 순서와 상태를 관리한다.



기본 순환

CHAT_MODE -> 건강 확인 요청 또는 센서 이상 -> QUESTION_MODE -> 최대 5회 질문/답변 -> 결과 요약 -> CHAT_MODE 복귀

2. 구성 요소별 역할

구성 요소	주요 역할	출력
Llama 3.2:1B	평상시 일상 대화, 사용자 입력 의도 분류, 질의 세션 시작 요청 감지, 3B 질문에 대한 사용자 답변 구조화 및 요약	대화 응답 또는 JSON 분류 결과
Llama 3.2:3B	현재 상태와 누적 답변을 참고하여 RAG 후보 중 다음 질문 선택. 필요 시 건강 정보 RAG 기반 답변 및 최종 요약 생성	candidate_id 또는 제한된 답변
Rule Engine	센서 threshold를 기반으로 이상 징후 종류, 초기 위험도, 우선순위, 반드시 확인할 안전 조건 결정	abnormal category, priority
RAG	현재 category, question intent, 위험도, 이전 답변, 이미 질문한 주제를 조건으로 적절한 질문 후보군 검색	질문 후보 목록
SeniorCareManager	모드 전환, 질문 단계, 현재 질문, 누적 답변, 중복 제거, 조기 종료, 응급 전환, 세션 종료 후 초기화 관리	다음 처리 경로와 상태

운영 원칙

1B는 자유로운 사용자 문장을 이해하기 위한 경량 모델이고, 3B는 제한된 후보 안에서 더 정교한 선택을 수행한다. 센서 판단과 안전 경계는 모델이 아니라 Rule Engine과 Manager가 관리한다.

3. 서비스 모드 정의

CHAT_MODE - 일상 대화 모드	QUESTION_MODE - 질의 응답 모드
담당 모델: Llama 3.2:1B 터미널 표시: [일상대화 모드] 사용자: 입력 의미: 자유 대화, 상태 확인 요청, 명령, 새로운 질문 주요 처리: 일상 대화 응답, 의도 분류, 건강 확인 요청 감지 전환 조건: 사용자가 상태 확인을 요청하거나 센서 이상에 대한 질문 세션이 필요할 때	담당 모델: 3B 질문 선택 + 1B 답변 해석 터미널 표시: [질의 응답 모드 1/5] [현재 질문에 대한 대답]: 입력 의미: 방금 제시된 질문에 대한 답변 주요 처리: RAG 재검색, 3B 질문 선택, 1B 답변 분류, state 갱신 종료 조건: 최대 5회, 충분한 정보 확보, 응급 신호, 사용자 중단

중요한 해석 원칙

QUESTION_MODE에서 들어오는 터미널 입력은 기본적으로 새로운 자유 대화가 아니라 현재 질문에 대한 답변으로 처리한다. 단, 종료/중단 명령과 명백한 off-topic 입력은 별도로 분류한다.

4. 최대 5회 질의 세션 흐름

질문은 3B가 한 번에 5개를 생성하는 방식이 아니다. Manager가 매 회차마다 답변을 반영하고 RAG를 다시 검색한 뒤 3B를 다시 호출한다.

1. 세션 진입	Rule Engine 결과와 현재 대화 상태를 바탕으로 QUESTION_MODE를 시작한다.
2. 후보 검색	현재 category, intent, priority, 이전 답변, asked_topics를 사용해 RAG 후보를 검색한다.
3. 질문 선택	3B는 후보 밖의 질문을 만들지 않고 candidate_id 하나를 선택한다.
4. 답변 수집	터미널을 [현재 질문에 대한 대답] 모드로 표시하고 사용자의 답변을 받는다.
5. 답변 해석	1B가 positive/negative/uncertain, severity, emergency, summary 등의 JSON으로 구조화한다.
6. 상태 갱신	Manager가 state, priority, question_intent, asked_topics를 갱신한다.
7. 반복 또는 종료	다음 질문이 필요하면 2번으로 돌아가고, 최대 5회 또는 조기 종료 조건이면 요약 후 CHAT_MODE로 복귀한다.

5회는 최대값

응급 신호가 발견되거나 충분한 정보가 확보되면 5회를 채우지 않고 종료한다. 반대로 답변이 불명확한 경우 확인 질문을 포함하여 최대 5회까지 진행한다.

5. 터미널 표시 및 상태 전환 예시

[일상대화 모드] 사용자: 오늘 조금 피곤해요.
시스템(1B): 많이 피곤하셨군요.無理하지 말고 쉬어 보세요.

[일상대화 모드] 사용자: 내 상태를 확인해 줘.
시스템: 상태 확인을 위해 몇 가지 질문을 드리겠습니다.

[질의 응답 모드 1/5]
시스템 질문(3B 선택): 지금 숨쉬기가 평소보다 힘드신가요?
[현재 질문에 대한 대답]: 아니요, 걸을 때만 조금 숨이 차요.

1B 답변 해석 -> Manager state 갱신 -> RAG 재검색 -> 3B 다음 질문 선택

질의 종료 후:
시스템: 상태 확인이 완료되었습니다. 일상 대화 모드로 돌아갑니다.
[일상대화 모드] 사용자:

상태	핵심 저장 정보
CHAT 상태	현재 모드, 최근 대화 요약, 센서 이상 여부, 세션 시작 요청 여부
QUESTION 상태	step/max_steps, abnormal_category, current_priority, question_intent, current_question, asked_candidate_ids, asked_topics, answers, emergency, finished
종료 후	질의 결과 요약을 대화 메모리에 남기고 question state를 초기화한 뒤 CHAT_MODE로 복귀

최종 설계 요약

1B는 대화의 입구와 사용자 답변 해석을 담당하고, 3B는 질의 세션에서 RAG 후보 중 가장 적절한 질문을 선택한다. SeniorCareManager는 두 모드의 전환과 최대 5회 반복을 통제하며, 질의 종료 후 항상 일상 대화 모드로 되돌린다.